

**Autor: Samuel Espitia Cruz**

**Repositorio:** <https://github.com/juanfope/connect-4-Proyecto-IA-2026-2/tree/Samuel>

## 1. IDEA PRINCIPAL DEL AGENTE Y DIFERENCIACIÓN

El agente desarrollado se fundamenta en el algoritmo de Búsqueda en Árbol de Montecarlo (MCTS), un enfoque de planificación probabilística. A diferencia de los métodos puramente reactivos o deterministas, MCTS no depende de una evaluación estática y exhaustiva del tablero entero, sino que expande de manera asimétrica un árbol de decisiones concentrando su presupuesto de cómputo en las variantes que estadísticamente prometen mayor tasa de éxito.

**Diferenciación Estructural del Grupo:** Mientras que las arquitecturas del resto del grupo se fundamentan en un algoritmo Minimax con poda Alpha-Beta de horizonte fijo cuyo rendimiento depende estrictamente de una función heurística manual que puntúa estáticamente configuraciones de fichas a un bajo costo computacional, este agente se distingue por su flexibilidad adaptativa generalizada. Esta diferencia es crítica: el enfoque Minimax del grupo es estructuralmente simétrico y queda completamente "ciego" más allá de su quinta jugada, requiriendo parches heurísticos diseñados por el programador para intuir la calidad de un tablero intermedio. En contraste, el MCTS expande su árbol de decisiones de forma asimétrica mediante muestreo probabilístico. Al evaluar los estados a través de simulaciones completas en lugar de ecuaciones de puntuación rígidas.

## 2. CONFIGURACIÓN MULTIVARIABLE DEL AGENTE

El rendimiento de la arquitectura MCTS no es una constante atómica; se calibra manipulando parámetros de recursos y sub-estrategias operativas. Para este estudio se estructuraron tres versiones principales:


- **Versión 1 (Línea Base - 400 Sim):** Configurada con un presupuesto moderado de 400 simulaciones por turno y una constante de exploración estándar  $c = \sqrt{2}$ . Balancea el tiempo de ejecución en CPU con un horizonte de búsqueda intermedio.
- **Versión 2 (Optimización Masiva - 800 Sim):** Duplica el presupuesto computacional a 800 simulaciones manteniendo  $c = \sqrt{2}$ . Diseñada para profundizar el horizonte táctico y erradicar la ceguera ante horquillas en fases complejas.
- **Versión 3 (Sobre-explotación - 800 Sim /  $c=1.0$ ):** Mantiene las 800 simulaciones, pero restringe el ímpetu de exploración bajando  $c$  a 1.0, forzando al algoritmo a profundizar de manera prematura en las primeras ramas de éxito detectadas.

## 3. ANÁLISIS EMPÍRICO DE RENDIMIENTO Y MDPS DE EVALUACIÓN


Los agentes fueron testeados bajo un control riguroso de roles a lo largo de series de hasta 100 enfrentamientos. Este volumen masivo de partidas garantizó la significancia estadística de la muestra, mitigando anomalías por jugadas fortuitas. La telemetría recolectada registró de forma pura la tasa de éxito global, el promedio de movimientos por juego y la velocidad de colapso de cada política frente a amenazas directas. El MCTS demostró inmunidad total ante el agente aleatorio con un presupuesto base de 400 simulaciones. Frente al oponente Heurístico, la manipulación de los parámetros fue determinante: la versión base (400 sim) registró una derrota prematura en el turno 6 por ceguera de apertura, pero al escalar los recursos a 800 simulaciones, el WR subió al 99%, blindando el juego medio y retrasando la derrota crítica al turno 9. No obstante, asfixiar la curiosidad del árbol con  $c=1.0$  y 800 sim provocó un sesgo de sobreexplotación, bajando el rendimiento al 91% global.

Finalmente, el Mirrormatch aisló de forma pura la ventaja de comenzar, registrando un 53% WR como Rojo frente a un 42% como Amarillo, definiendo una guerra de desgaste posicional de 32.9 movimientos promedio.


#### MCTS (simulations=300) vs Agente Aleatorio




**Mirrormatch: MCTS vs MCTS (Auto-juego)**  
(Aislamiento de la ventaja de salida | Simulations=800, N=100)




**Análisis de Rendimiento por Color: MCTS vs Agente Heurístico Codicioso**  
(Muestras balanceadas | Simulations=400)



**Análisis de Rendimiento por Color: MCTS vs Agente Heurístico Codicioso**  
(Muestras balanceadas | Simulations=800)



**Análisis de Rendimiento por Color: MCTS vs Agente Heurístico Codicioso**  
(Muestras balanceadas | Simulations=800)



## 4. Conclusiones y Propuestas de Mejora

A partir de los cuellos de botella identificados en la telemetría, se proponen dos líneas de desarrollo: }

- Libro de Aperturas Heurístico: Esta estrategia de bajo costo ahorra presupuesto de simulaciones en la apertura, reservando la potencia de cómputo exclusivamente para los turnos críticos
- Arquitectura SL-MCTS (Redes de Política-Valor): Sustituir por completo los rollouts aleatorios por una red neuronal de dos ramas (Política y Valor) que trunque la profundidad y guíe la búsqueda

Para concluir se puede evidenciar que el balance entre simulaciones y la constante  $c$  es crítico. Reducir la exploración  $c$  1.0 con la idea de ahorrar tiempo resulta contraproducente bajo presupuestos altos. Asimismo, la demanda de recursos la dicta el oponente: mientras que un entorno aleatorio se domina con mínimo cómputo, un sistema experto exige exprimir el presupuesto de búsqueda al máximo para evitar descuidos tácticos.